

1 Detalles del Problema.

Nota: gran parte de los detalles son extraídos del entorno de contexto.

En este caso se estudiarán las necesidades de infraestructura de Finandes, una empresa ficticia que se dedica a la captación y colocación de recursos financieros.

Aunque desde muchos puntos de vista sería deseable poder definir una infraestructura completamente nueva, que responda a las necesidades de los diferentes procesos de la organización, es poco práctico hacer “borrón y cuenta nueva” de la infraestructura actual. Por esta razón se debe plantear una transición gradual, que tomará cierto tiempo, para ir de la infraestructura actual a la ideal. Teniendo en cuenta esto, en la presentación del caso se incluyen, tanto las características de las aplicaciones y datos que deben ser soportados, como las de la infraestructura actual, las cuales condicionan la definición de la nueva infraestructura.

Finandes tiene 900.000 afiliados. Además, la empresa tiene 35 oficinas distribuidas en varios municipios del país. En todas ellas se prestan los mismos servicios y todas tienen acceso electrónico al centro de datos ubicado en Bogotá. Se estima que hay unos 50 funcionarios haciendo transacciones de recepción de documentos. Estas transacciones son dirigidas por un BPM que encadena los procesos de validación de datos e información hasta darle respuesta a la persona que solicita un trámite.

El servicio que presta la entidad es un servicio de alta sensibilidad social por lo que requiere un nivel de continuidad alto; los servicios informáticos deben estar disponibles en las oficinas en las horas laborales (de lunes a viernes de 9 am a 3 pm), y vía Internet los siete días de la semana entre 7 a.m. y 12 p.m. Además, se considera que el servicio al afiliado, el cual es una prioridad en este momento, depende totalmente de un buen funcionamiento de los sistemas de información, lo cual implica, no sólo que las aplicaciones deben estar disponibles, sino que el tiempo de respuesta desde cualquier oficina y desde Internet debe ser menor o igual a 3 segundos. Por la razón anterior, se ha determinado que las aplicaciones de apoyo a la atención al público estén siempre disponibles en el horario indicado (no se desea que en los sitios de atención se diga que no hay servicio porque no hay línea, como ocurre eventualmente en la actualidad)

Por las razones mencionadas, se requiere un plan de continuidad para el caso de que haya un incidente mayor que impida que el centro de datos funcione adecuadamente.

La información más importante que maneja la empresa tiene que ver con los recursos manejados tanto por personas jurídicas como naturales. En el caso de las empresas, Finandes se ocupa de sus pagos de nómina y las gestiones financieras propias de una empresa. En el caso de las personas, Finandes ofrece productos de inversión y préstamos personales.

Los datos son de dos tipos: anteriores y posteriores a la reforma tributaria de este año. En cuanto al primer tipo de datos, Finandes debe gestionar la información de los recursos manejados por Finandes previo a la mencionada reforma, junto con las reglas de negocio implementadas para responder a la reglamentación correspondiente. En lo que concierne a la segunda tipología de datos Finandes debe gestionar la información de los recursos manejados junto con la reglamentación que los rige. Se va a requerir una nueva base de datos homogénea para los dos tipos de datos.

Ante las dificultades que ha tenido con su operación, Finandes ha decidido privilegiar la subcontratación de servicios en la medida de lo posible, lo cual se aplica, entre otros, a aspectos que tengan que ver con las tecnologías de información y comunicaciones, así como con captura y digitación de datos. Así mismo, está migrando a transacciones sin papel haciendo que el usuario incremente el número y tipo de transacciones que realiza vía electrónica (app y web).

La empresa tiene algún retraso tecnológico y se desea transformarla para que cuente con una infraestructura tecnológica moderna que le permita desempeñar cabalmente sus funciones. Para esto ha decidido renovar su infraestructura y el objetivo es que esto pueda ser hecho en el menor tiempo posible. Después de un análisis cuidadoso se ha establecido que esta debe continuar centralizada, con sede en Bogotá.

El proceso de afiliación está subcontratado con una entidad externa y esta reporta periódica y electrónicamente la información correspondiente, para ser procesada en forma batch. Con base en ella se procede a actualizar las bases de datos de la entidad.

El proceso de captación lo hacen las sucursales a nivel nacional. El manejo relacionado con préstamos es intenso en procesamiento pues se requiere hacer conciliaciones tripartitas entre los recursos disponibles, el registro de transacciones del usuario y las captaciones y colocaciones de la entidad. Estos procesos implican varias verificaciones generan archivos con las inconsistencias encontradas. También se requiere el cobro de

intereses no realizados. Este proceso implica el control del debido pago de los clientes. Los procesos de analítica encadenan diferentes aplicaciones y bases de datos mediante un flujo de trabajo de estilo BPM, así como un análisis de las redes sociales de los clientes.

La aplicación de nómina ofrece dos servicios: consultas diarias y consolidación a fin de mes. El primero necesita un tiempo de respuesta mínimo pues los empleados usan la consulta para atender en las oficinas de servicio al público. El segundo servicio se realiza a fin de mes, su procesamiento es tipo batch y puede durar varios días. Además, por su impacto una falla sería muy costosa. Este sistema debe tener un esquema de contingencia totalmente probado y certificado.

El portal web y la app debe permitir un número creciente de operaciones tanto para personas jurídicas como naturales.

Se calcula que en la empresa hay aproximadamente 15 bases de datos que ocupan en total 100 terabytes de espacio. Las bases de datos más importantes, las relacionadas con afiliados y empresas, son usadas por la mayoría de las aplicaciones. En particular, son usadas por dos aplicaciones, captación y nómina, las cuales deben tener una alta disponibilidad y un buen tiempo de respuesta. Además, como se dijo arriba, hay que tener mucho cuidado con las intensivas en procesamiento porque podrían generar problemas de contención. Las copias de respaldo (“backups”) deben permitir la operación de las aplicaciones misionales durante las horas hábiles.

La continuidad de la operación está garantizada hoy con la contratación de un centro de datos alternativo en otra ciudad, cuyas bases de datos deben estar sincronizadas con las de la entidad. Esto quiere decir que cualquier transacción que se haga en la entidad se debe reflejar también en el centro alternativo. Este centro de datos es administrado por la entidad encargada de hacer las afiliaciones. Todas las sucursales tienen conexión al centro de datos central, el cual reside en Bogotá. De ellas, 12 están ubicadas en la ciudad de Bogotá. Se desea que el procesamiento se siga haciendo de forma centralizada, en Bogotá. Además de lo anterior, la entidad debe conectarse electrónicamente con 5 puntos ubicados en entidades externas (por ejemplo, la empresa que se encarga de las afiliaciones, el banco de la república y la superfinanciera). Hay una conexión especialmente importante que es la actualización en línea con el centro de datos alternativo, el cual está ubicado en otra ciudad. Hace aproximadamente un año, el servidor activo fue repotenciado, aumentando su capacidad de memoria y procesamiento (10 procesadores físicos Xeon EPY C 73F3 y 128GB de memoria RAM). El proveedor del manejador de base de datos Oracle, ha sugerido que la configuración mínima de memoria RAM de este servidor sea de 512 GB (la máxima posible en ese servidor). Cada nuevo slot de 64GB cuesta aproximadamente 100 millones de pesos. Este servidor también puede ser actualizado con procesadores con más núcleos, con un costo aproximado de 10 millones de pesos por procesador. El costo anual de licenciamiento de Oracle por núcleo de procesador es de aproximadamente 10 millones de pesos.

El servidor pasivo es menos poderoso que el activo y se estima que en caso de falla es poco probable que pueda asumir toda la carga del sistema

1.1 Principios tecnológicos

Dentro de los principios tecnológicos que se han definido en la empresa con respecto a la infraestructura están los siguientes: el procesamiento debe ser centralizado, se continuará con la subcontratación de las afiliaciones y el centro alternativo, se seguirá trabajando con procedimientos almacenados, se trabajará con el ambiente de desarrollo de Java y con el ambiente de bases de datos Oracle. Puede que algunas de estos principios cambien en el mediano, pero no en el corto plazo.

Existen también otros lineamientos:

- Exigir que los terceros contratados dispongan de planes de contingencia y continuidad debidamente documentados.
- Implementar mecanismos de cifrado fuerte para el envío y recepción de información confidencial con los terceros contratados.

1.2 Infraestructura existente

Dado el enunciado dado arriba, sabemos que tenemos, bajo control completo de la compañía:

- un BPM (Business Process Manager)
- un portal web (sin especificaciones de frameworks o tecnologías)
- una app móvil (sin especificaciones de frameworks o tecnologías)
- 37 servidores (solo nos centraremos en aquellos afectados por la estructura TO-BE)
- 15 bases de datos con 100 TB de datos.

- conexiones con el banco, la superfinanciera, y las aplicaciones para las aplicaciones.

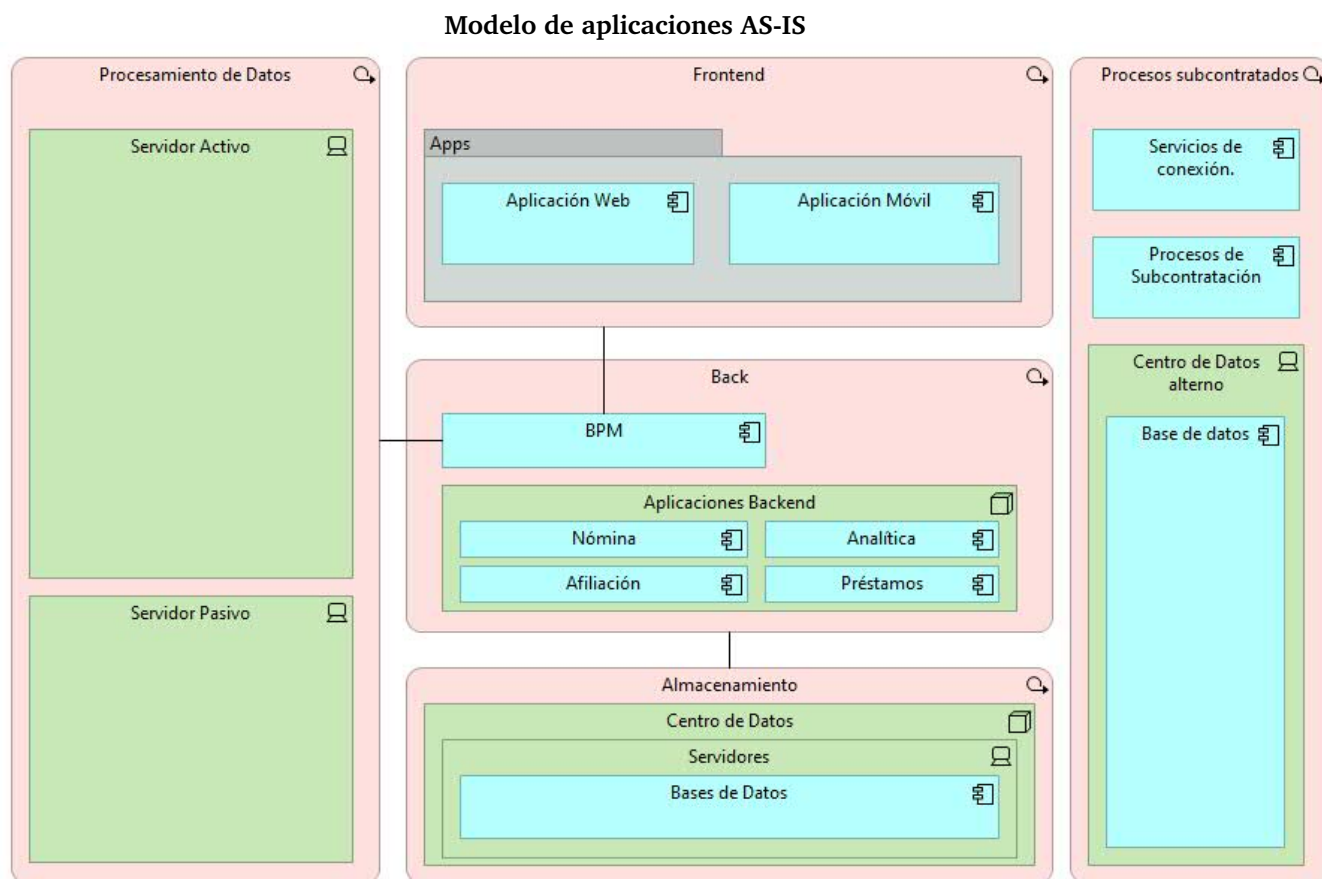
Y, tenemos de forma subcontratada:

- Un proceso de subcontratación.
- los servicios de conexión tienen software propietario que no controlamos como parte de su servicio. se asumirá como una caja negra este producto dentro de nuestro diseño.
- un centro de datos alterno.

Fuera de esto, se va a asumir que:

- La arquitectura de las aplicaciones, basada en procedimientos almacenados (“stored procedures”), dificulta la distribución de la carga computacional requerida para su funcionamiento lo que contribuye a los problemas de sobrecarga de los servidores de base de datos institucionales.
- La mayoría de los servidores tienen más de 4 años de uso (algunos tienen más de 10 años de uso). Hay aproximadamente 39 servidores físicos en el centro de cómputo.
- En lo que se refiere a los servidores de apoyo a las bases de datos, que son actualmente dos, organizados en un clúster activo-pasivo, se ha determinado que están sobrecargados.

Estas reglas se pueden visualizar a partir del siguiente diagrama:



2 Diseño de las soluciones.

2.1 secciones a evaluar.

Hay 7 principales secciones que se evaluarán:

- Afiliación: 100 transacciones al día que se procesan en la noche y que generan mucha carga de entrada/-salida en almacenamiento
- Captación: estos ingresos de dinero, de los cuales hay unos 20,000 al día, se consolidan en la noche y generan mucha carga en almacenamiento.

- Préstamos: 4,000 operaciones diarias que se deben resolver en línea y que requieren alta capacidad de cómputo
- Analítica: se ejecutan unas 500 diarias, la mitad de las cuales son en línea y son grandes consumidoras de procesamiento.
- Nómina: Se procesan unas 20,000 a finales de mes con alto consumo de procesamiento y de operaciones de entrada/salida
- App y Web: se espera pasar de 2.000 a 10,000 operaciones diarias en los próximos meses. Son intensivas en operaciones de entrada/salida

Para cada una de estas, se desarrollará una arquitectura diferente teniendo en cuenta sus requerimientos. Los requerimientos se van a clasificar como:

- **Desempeño**
- **Disponibilidad**
- **Escalabilidad**
- **Capacidad**

Para estos casos de uso, se establecen los siguientes requerimientos:

General:

- En general todo se espera poder mantener en una misma granja de servidores, sin el uso de multinube.
- Debe poder reutilizarse la tecnología existente, dado a que esto reduce costos

Afiliación:

- **Desempeño**
La carga de entrada/salida es muy intensiva, por lo que la solución debe poder hacer estas operaciones de forma satisfactoria.
- **Disponibilidad**
Dado que la aplicación se usa de forma diaria, debe estar disponible de forma relativamente constante.
- **Escalabilidad**
La carga es procesada en la noche, por lo que es perfectamente posible escalar y desescalar en medida de que sea necesario.

Captación:

- **Escalabilidad**
Dado que este servicio solamente se utiliza a finales de mes, solamente es necesario mantener este servicio durante ese espacio de tiempo, por lo que debe poder escalarse la capacidad del servicio para acomodar la demanda, pero pueden quitarse dichos recursos en las ocasiones que no sean utilizados.
- **Capacidad**
Esta es la aplicación que tiene el mayor número de peticiones en un periodo corto de tiempo. Por lo tanto debe poderse procesar de forma eficiente esta cantidad de transacciones al final de cada mes sin sobrepasar la barrera de sobrecarga.

Analítica:

- **Desempeño**
Finandes nos ha suministrado una copia de la consulta principal que resuelve la aplicación de Analítica y espera su ayuda para determinar la infraestructura de TI necesaria para cumplir con un tiempo de respuesta de este servicio menor o igual a 4 segundos por lo menos en el 95 % de las veces
Gran parte del trabajo hecho de parte de Analítica sera dado con respecto a esta.

Nómina:

- **Desempeño**
La alta necesidad de operaciones de entrada y salida implican una necesidad de que las operaciones sean eficientes.

- **Capacidad**

Se procesan 20.000 solicitudes en hora pico. Es la aplicación que requiere una mayor capacidad al ser utilizada.

App y Web:

- **Desempeño**

Gran parte del desempeño de esta aplicación esta fuera de nuestro control, cosas como la conexión del cliente o la calidad de su conexión puede afectar el servicio. Sin embargo, debe poderse mantener un tiempo de respuesta aceptable.

- **Disponibilidad**

Dado que esta es nuestra principal conexión digital con los clientes, es importante que el programa tenga una alta disponibilidad. los tiempos de respuesta deben minimizarse u ocultarse al individuo que use la aplicación

- **Escalabilidad**

Se espera lograr que la aplicación escale su capacidad de 2,000 a 10,000 solicitudes por día en los próximos meses. Esto implica un aumento permanente de la capacidad del sistema con respecto al modelo AS-IS.

- **Capacidad**

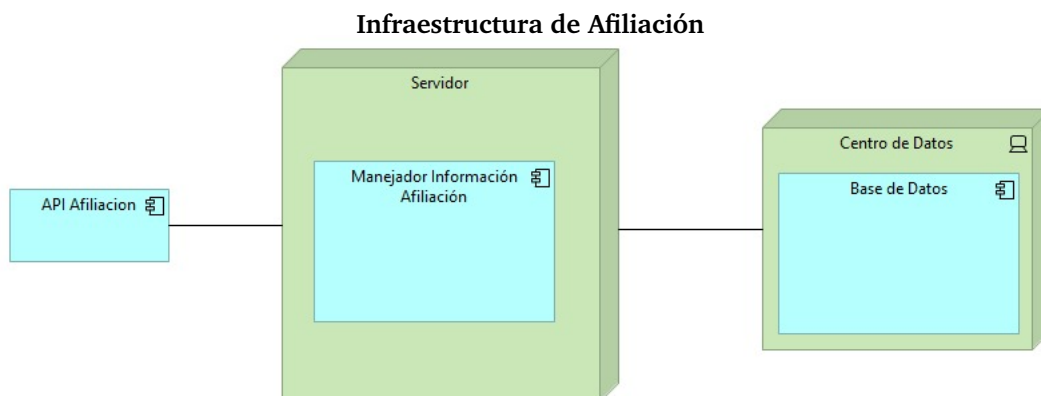
La capacidad de esta capacidad, aunque no es constante en práctica, se asumirá de forma constante. Sin embargo, se asumirá para las pruebas la capacidad máxima

2.2 Diseños individuales

2.3 Afiliación

Debido a que ya se contrato a un tercero que realiza todo el proceso de afiliación, y cuyo objetivo es enviar la información relacionada con este proceso, lo único que queda por evaluar es el procedimiento de recepción de información y guardado en base de datos. Teniendo en cuenta esto, se propone como solución una arquitectura monolítica que reciba la información, y la transforme de manera que se pueda almacenar en la base de datos sin que haya incompatibilidad en formatos o estructuras. Los principales beneficios de esta arquitectura es que, si la máquina tiene buenas especificaciones, el rendimiento de toda la API será optimo, además de que quita lugar a cualquier inconsistencia en la base de datos que podría ocurrir si hay múltiples servicios escribiendo en la base de datos de forma simultánea. Para garantizar que se cumpla el requerimiento de desempeño, se propone un escalamiento vertical del servidor utilizado para esta aplicación, pues aunque puede llegar a ser muy costoso, se trata de uno solo, que además solo necesita estar encendido en las noches, pues es en este tiempo en el que se realiza el proceso.

PD: Dado que esta aplicación procesa la información de forma batch, no hace falta una aplicación web que despliegue el servicio.



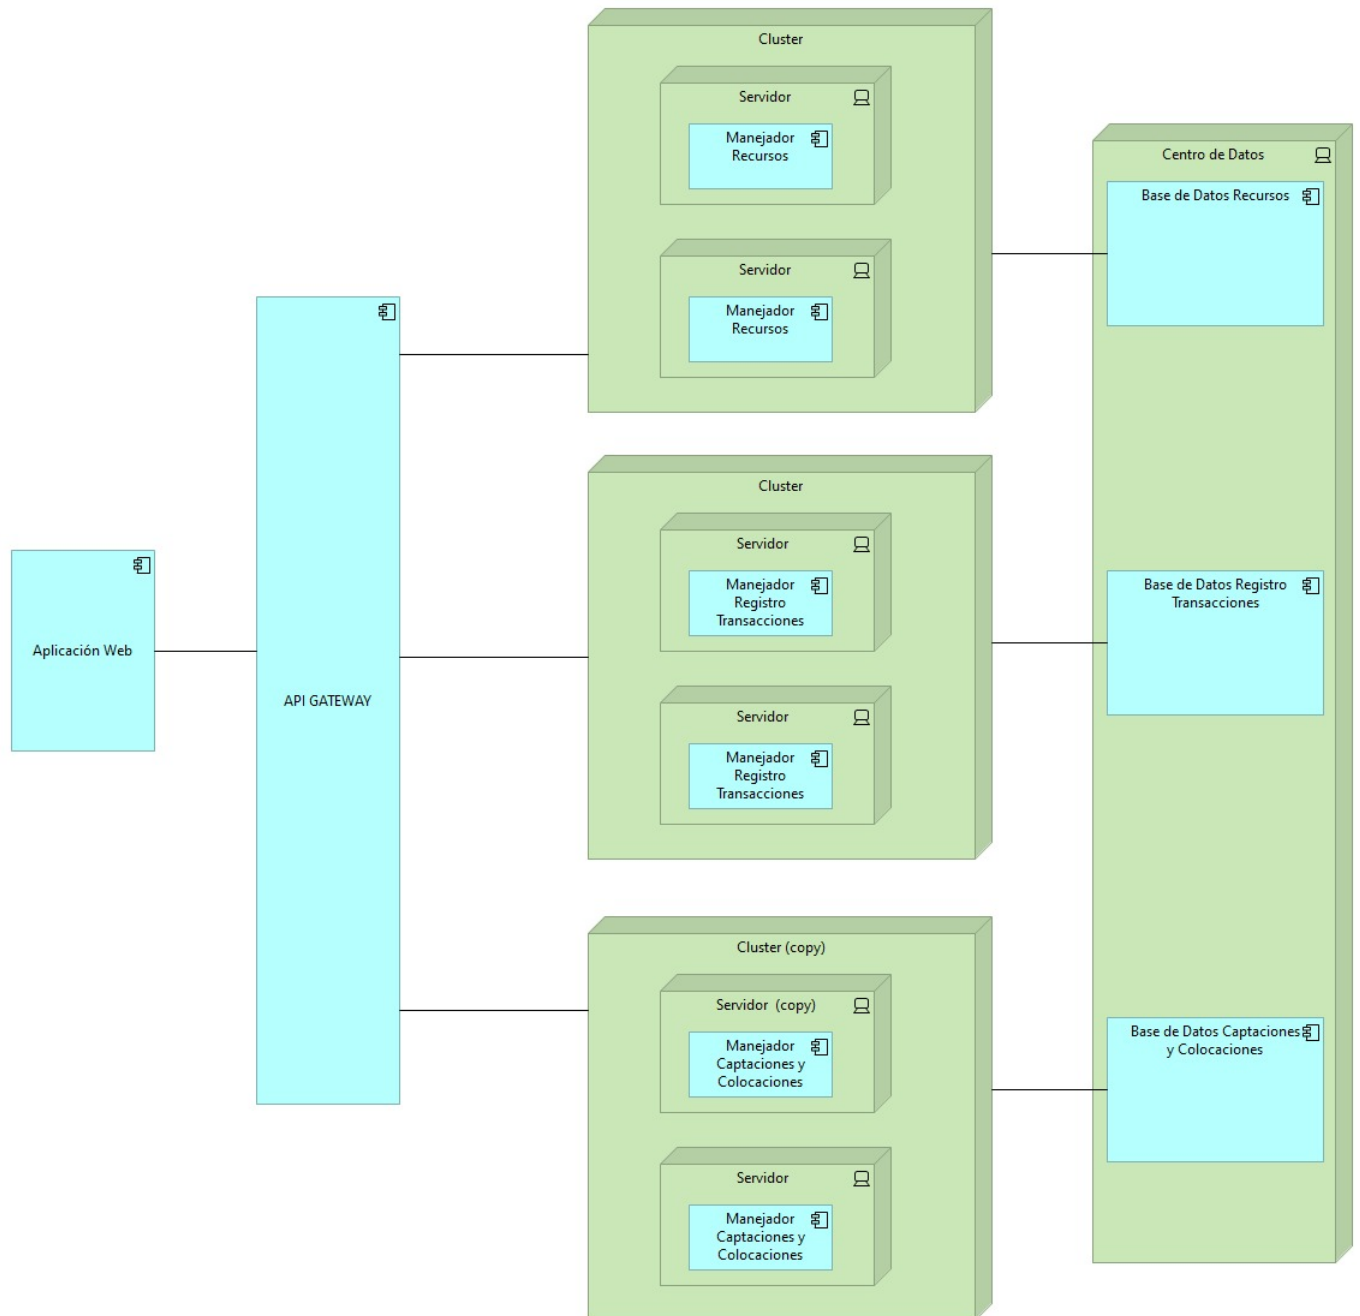
2.3.1 Analítica:

2.3.2 Captación

Teniendo en cuenta la cantidad de funcionalidades y la cantidad de peticiones que llega a recibir esta aplicación, se decidió recurrir a una arquitectura de microservicios, donde cada uno de ellos cuente con varios

servidores para garantizar todos los requerimientos identificados. Para enviar las peticiones al microservicio correspondiente se hace uso de una API GATEWAY, que direcciona a la API adecuada (pese a que existe un costo de desempeño al realizar el redireccionamiento, para efectos de este caso resulta insignificante). El primer microservicio hace referencia a el manejo de los recursos disponibles, el segundo al registro de transacciones y el tercero al manejo de las captaciones y colocaciones de la entidad. De esta forma cada microservicio trabaja de forma independiente entre sí, y se puede realizar la conciliación entre las tres partes de forma mucho más efectiva, pues errores de un microservicio no afectan a otro, y eficiente, pues los 3 microservicios son independientes entre sí, por lo que pueden trabajar de forma paralela sin ningún tipo de inconveniente. Así mismo, cada microservicio cuenta con su respectiva base de datos, de forma que se distribuya la información según se necesita y se garantiza mayor disponibilidad de las BD al haber menos consultas sobre una sola.

Infraestructura de Captación

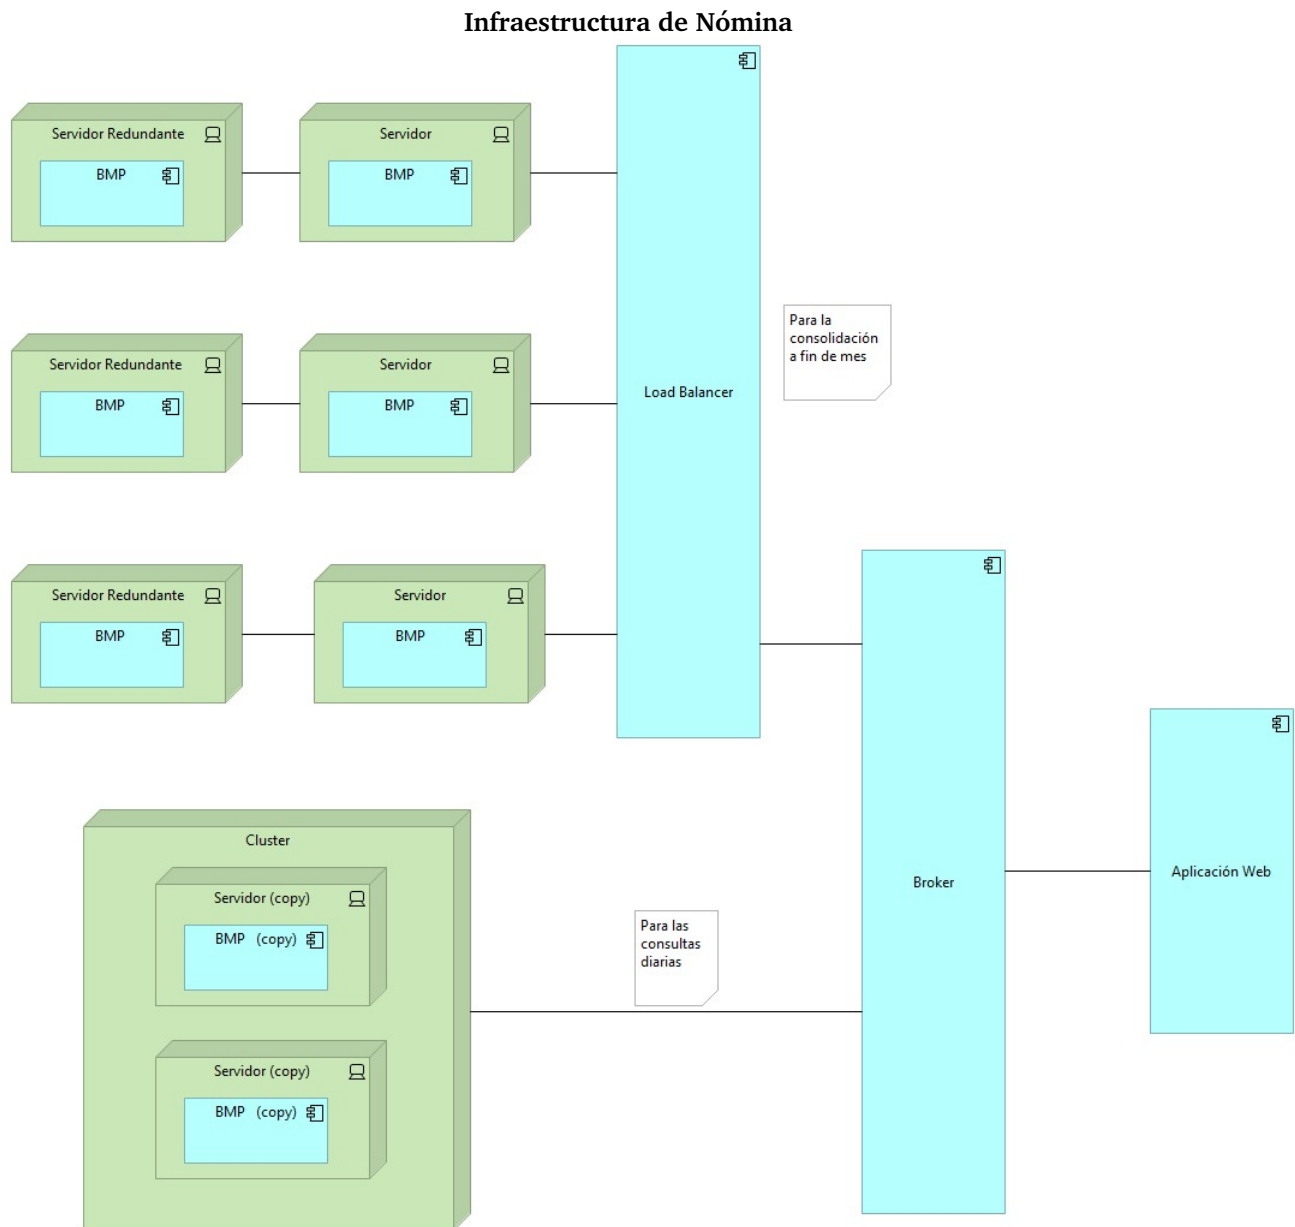


2.3.3 Nómina:

Teniendo en cuenta que los principales requerimientos que esta sección busca cumplir son desempeño, escalabilidad y disponibilidad, se propone como táctica el uso de un balanceador de carga. De esta forma, las peticiones que lleguen a la aplicación de nómina podrán ser distribuidas entre los servidores activos, garantizando así un mejor desempeño y tiempo de respuesta por parte de la aplicación, además de garantizar que una falla no tenga repercusiones muy importantes en los tiempos y costos. Por otro lado, para garantizar

que este escalamiento horizontal no resulte en costos desproporcionados que opaquen los beneficios de la solución, se propone utilizar el mecanismo de redundancia pasiva, de forma que los servidores adicionales no consuman energía mientras no sea necesario, y solo se activen cuando reciban el mensaje de que los servidores se encuentran sobrecargados.

Un beneficio adicional que ofrece esta táctica es la facilidad para agregar o eliminar servidores de la infraestructura. En otras palabras, si se ve durante las pruebas que no se está aprovechando los recursos adecuadamente, basta con desconectar la maquina del balanceador y reasignarle tareas que resulten de mayor consumo; así mismo, si queda en evidencia que se requieren más procesamiento para cumplir con los tiempos de respuesta definidos, es suficiente conectar una nueva máquina y replicar el contenido de las otras sobre ella, ya que todas cuentan con la misma información.



2.3.4 App y Web:

En este diseño, nos va a concernir no necesariamente el diseño interno de las apps de Finandes, sino su conexión con el resto de la infraestructura. Esto debido a que el diseño web y de las apps puede cambiar drásticamente entre sí (Swift no es lo mismo que Java, y Java no es lo mismo que Typescript.) y no le concierne a los temas de este curso. Lo que si nos concierne, sin embargo, es la conexión con el resto de la infraestructura. Vamos a entender la infraestructura bajo estas pretensiones:

- podemos usar los servidores dentro de la infraestructura AS-IS
- Se va a usar un failover dada la necesidad de disponibilidad para este servicio.

- Aunque la encriptación hace las transacciones mas lentas, es un mal necesario dada la necesidad por seguridad dentro del negocio.

Se va a pensar entonces, dadas estas condiciones, de esta forma la infraestructura:

